Arquitectura local en capas para la recomendación explicable de razas de perros de caza mediante embeddings y RAG

[NOMBRE DEL ALUMNO]
[INSTITUCIÓN]
Tópicos selectos de arquitectura de software · Unidad II
[NOMBRE DEL DOCENTE]
7 de noviembre de 2026

Producto local · Decisión auditable · Evidencia por página

Resumen ejecutivo

K9 BreedMatch es un sistema local de apoyo a la decisión que recomienda razas de perros de caza a partir de la presa objetivo, la modalidad de trabajo y el terreno. En lugar de entregar una conversación abierta, produce razas priorizadas, compatibilidad determinista, cobertura de evidencia y citas verificables por página.

La solución combina React, una API FastAPI organizada en capas, Ollama, Chroma y SQLite. Integra guardrails, caché exacta y semántica, enrutamiento de modelos, un ciclo acotado de agente, observabilidad y retroalimentación. Todo se ejecuta localmente y la aplicación web consume la API por HTTP.

La evaluación de recuperación obtuvo Recall@5 de 0.925, Hit@5 de 0.950 y MRR de 0.808 con Nomic. BGE-M3 obtuvo el mismo Recall@5 e Hit@5 y MRR de 0.825, pero duplicó el tiempo de embeddings y cuadruplicó el tamaño del modelo; por ello se conserva Nomic. Persisten limitaciones en la precisión de citas del chat, revisión humana y validación experta.

Contenido

1. Idea del producto

2. Dominio y corpus

3. Requisitos y atributos de calidad

4. Arquitectura

5. Comportamiento

6. Selección de modelos y enrutamiento

7. Diseño de las capas

8. Registro de decisiones

9. Evaluación

10. Limitaciones, riesgos y trabajo futuro

11. Referencias

12. Anexos

1. Idea del producto

1.1 Usuario, problema y momento de uso

El usuario principal es un cazador que necesita seleccionar una raza para una combinación concreta de presa, modalidad de trabajo y terreno. La tarea exige consultar descripciones dispersas, reconciliar vocabulario y distinguir evidencia documentada de opiniones generales.

1.2 Resultado y propuesta de valor

- Lista priorizada de razas, no una respuesta conversacional.
- Compatibilidad calculada por una política determinista y versionada.
- Cobertura que indica cuánto del perfil está documentado.
- Citas a página y advertencias sobre evidencia insuficiente.

1.3 Originalidad y medición

El producto combina recomendación semántica, verificación documental y explicabilidad. Su valor se mide mediante calidad de recuperación, consistencia del orden, cobertura de evidencia, latencia, utilidad registrada y capacidad para abstenerse.

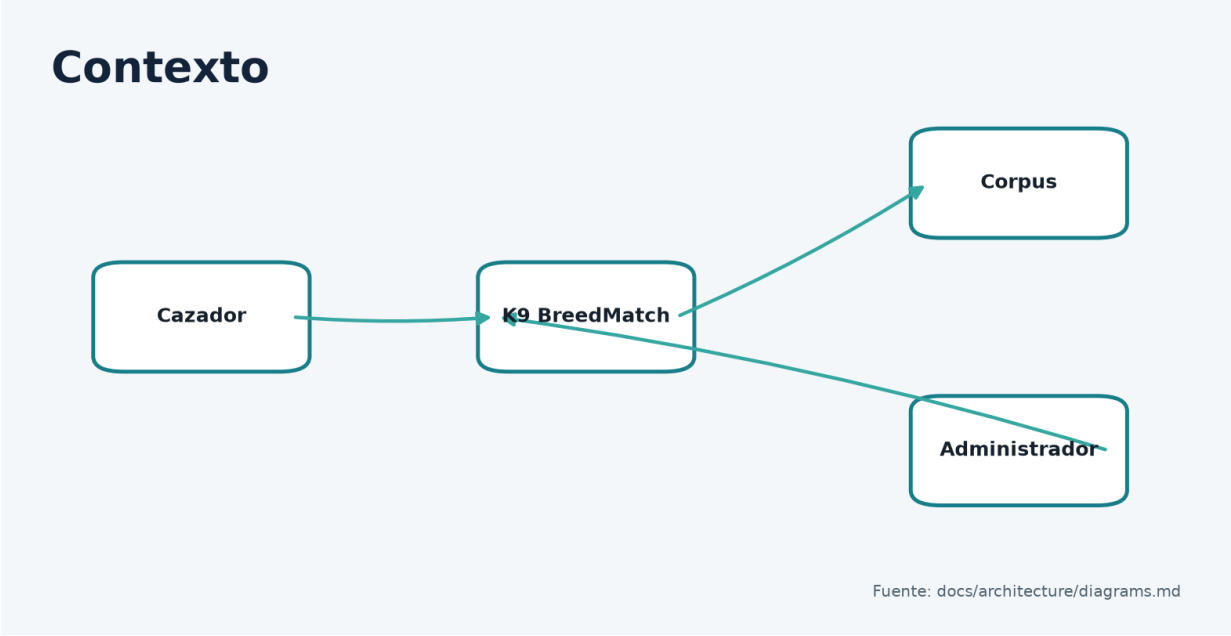


Figura 1. Contexto de uso de K9 BreedMatch.

2. Dominio y corpus

El dominio comprende razas de perros de caza y sus aptitudes documentadas. El corpus principal es Enciclopedia de los perros de caza, de Claudio De Giuliani, Editorial De Vecchi, 2019, ISBN 978-1-68325-599-4, con 243 páginas.

Propiedad	Valor
Formato	PDF
Páginas	243
Fragmentos línea base	786
Extracción	PyMuPDF; OCR registrado cuando aplica
Metadatos	documento, página, sección, raza
Uso	académico; permiso por confirmar

El PDF tiene derechos de autor y no debe redistribuirse fuera de la entrega. Dieciséis páginas fotográficas o con poco texto quedaron marcadas como candidatas a OCR. La licencia o permiso de uso académico debe confirmarse antes de la entrega.

3. Requisitos y atributos de calidad

Atributo	Medida o política
Fundamentación	Toda recomendación muestra fuentes
Latencia	p50 y p95 por ruta; caché observada
Privacidad	Modelos y datos en loopback
Seguridad	Guardrails de entrada y salida
Reproducibilidad	README, dependencias, preflight
Recursos	Modelos compatibles con 16–18 GB

4. Arquitectura

La regla de dependencia es descendente: la API delega en la orquestación y las capas inferiores se acceden mediante interfaces. Observabilidad y retroalimentación son transversales.

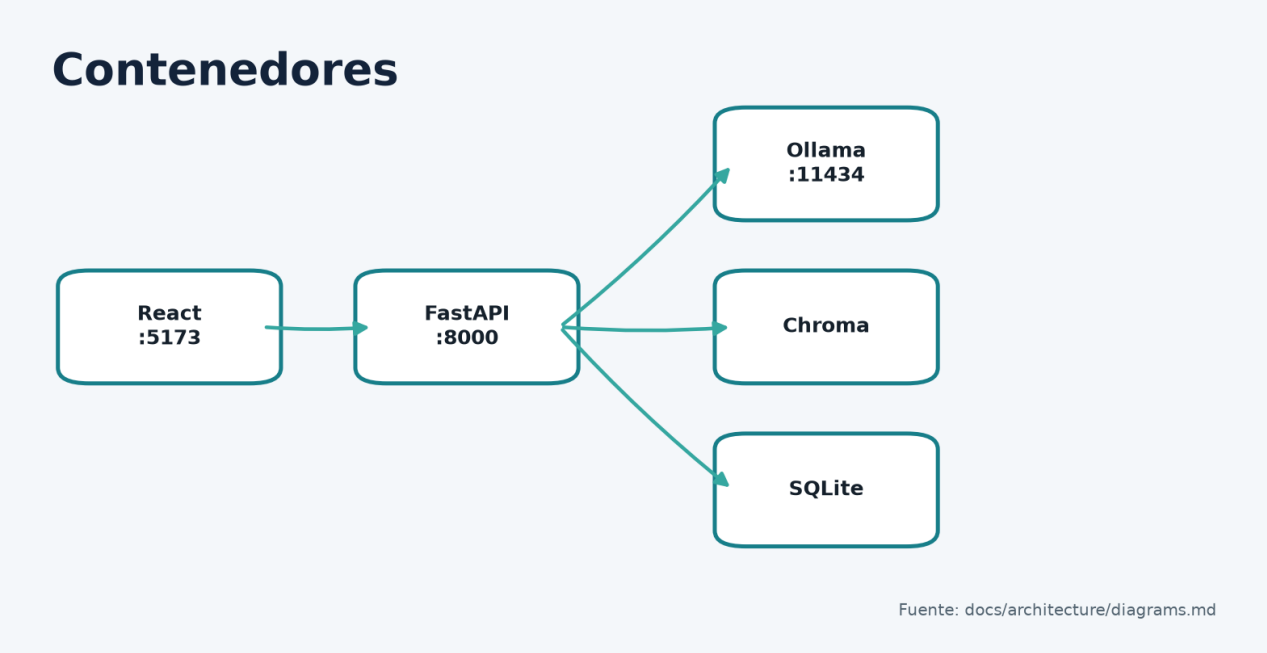


Figura 2. Vista de contenedores.

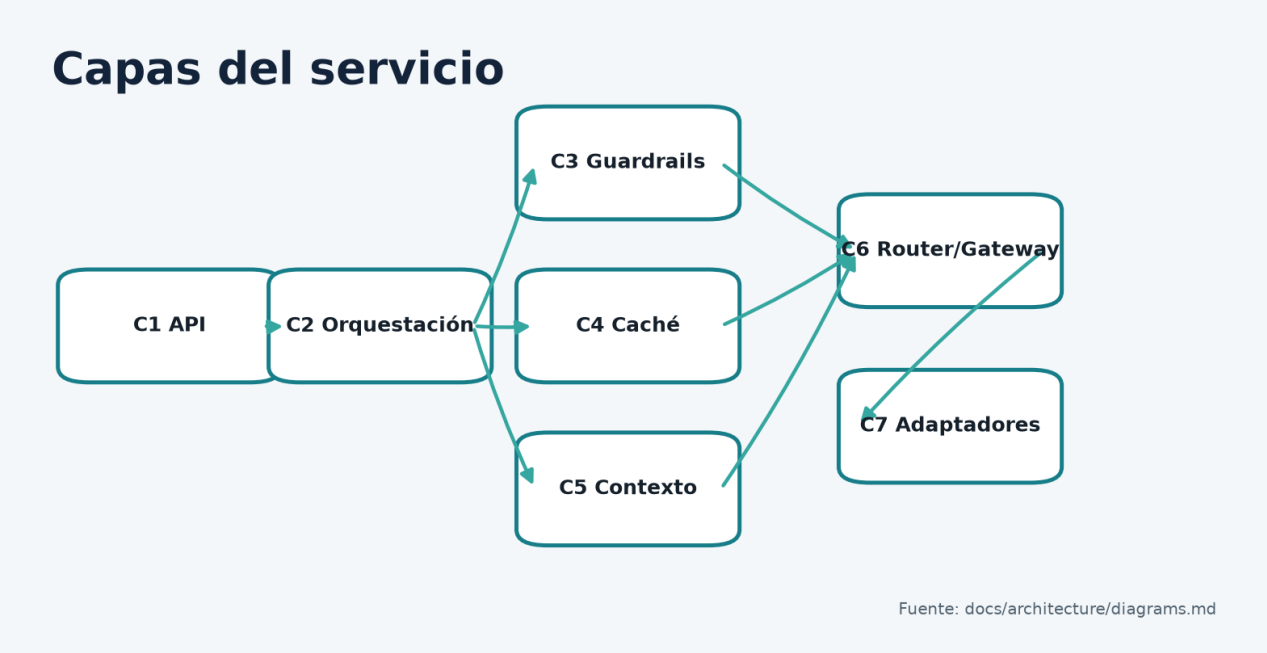


Figura 3. Capas C1–C7 y transversales T1–T2.

4.1 Componentes

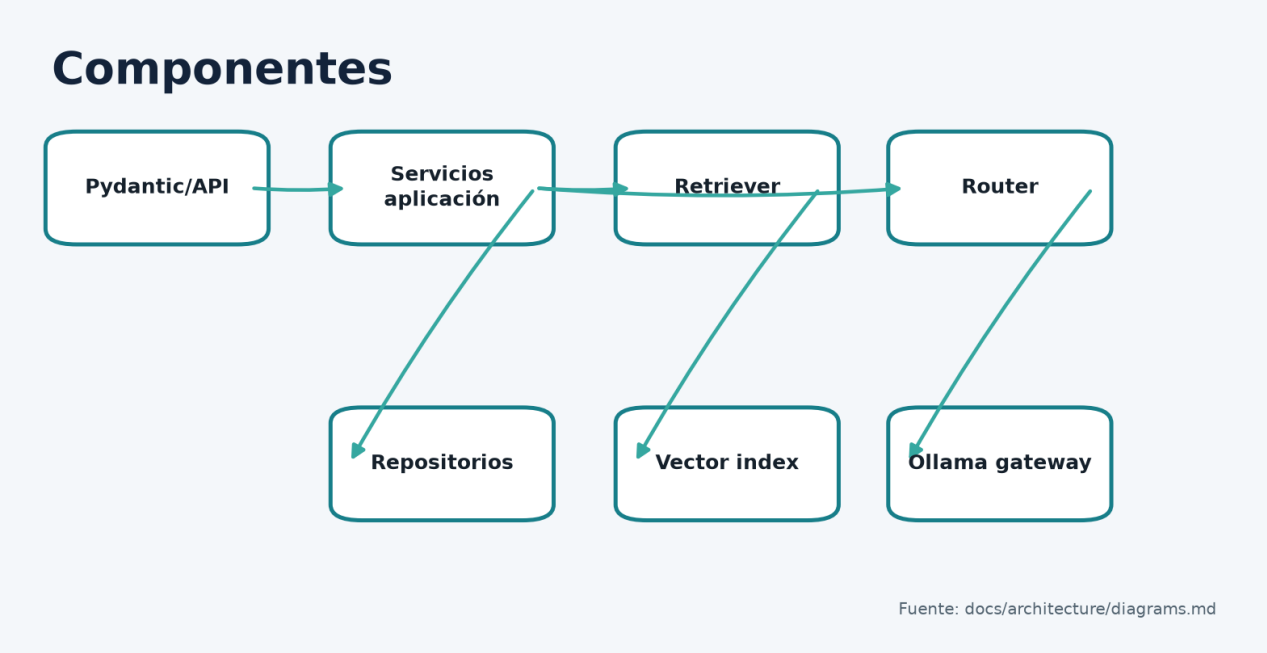


Figura 4. Componentes principales e interfaces.

Los puertos desacoplan servicios de aplicación y adaptadores. Chroma puede sustituirse sin modificar la API o la política de recomendación; SQLite es la fuente de verdad operacional.

4.2 Despliegue local

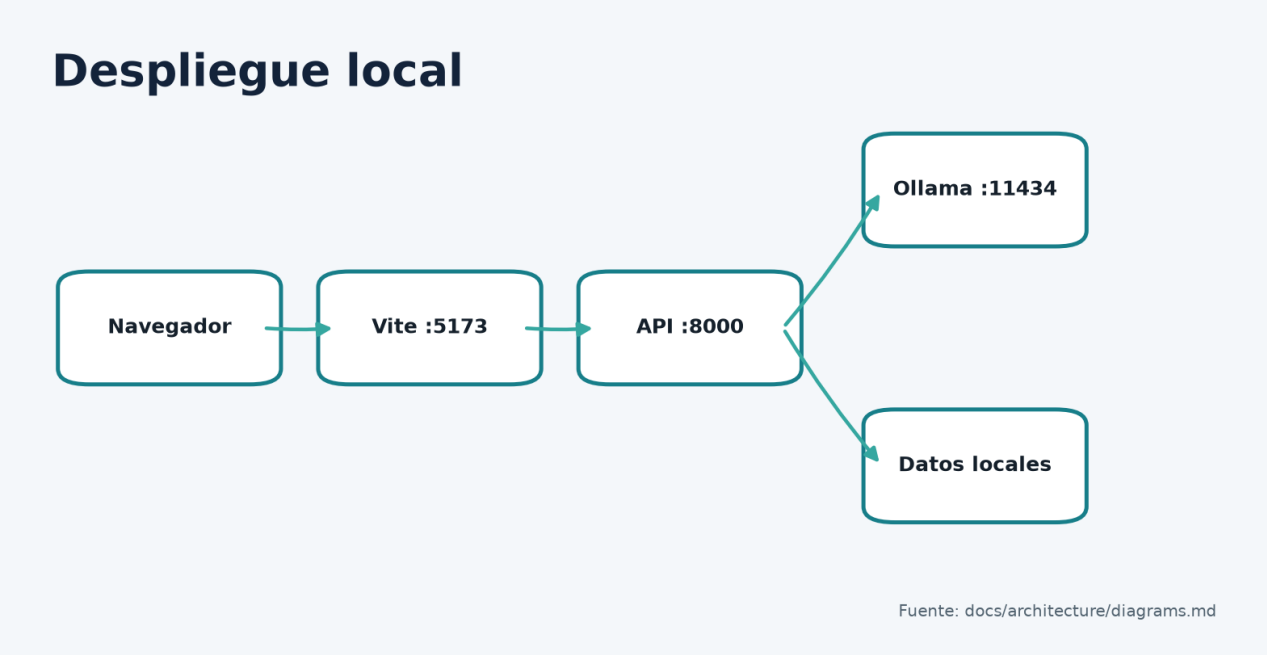


Figura 5. Despliegue en el equipo del estudiante.

Proceso	Puerto / recurso
React/Vite	127.0.0.1:5173
FastAPI	127.0.0.1:8000
Ollama	127.0.0.1:11434
Chroma	persistencia local
SQLite	datos, caché, trazas, feedback

5. Comportamiento

5.1 Ingesta

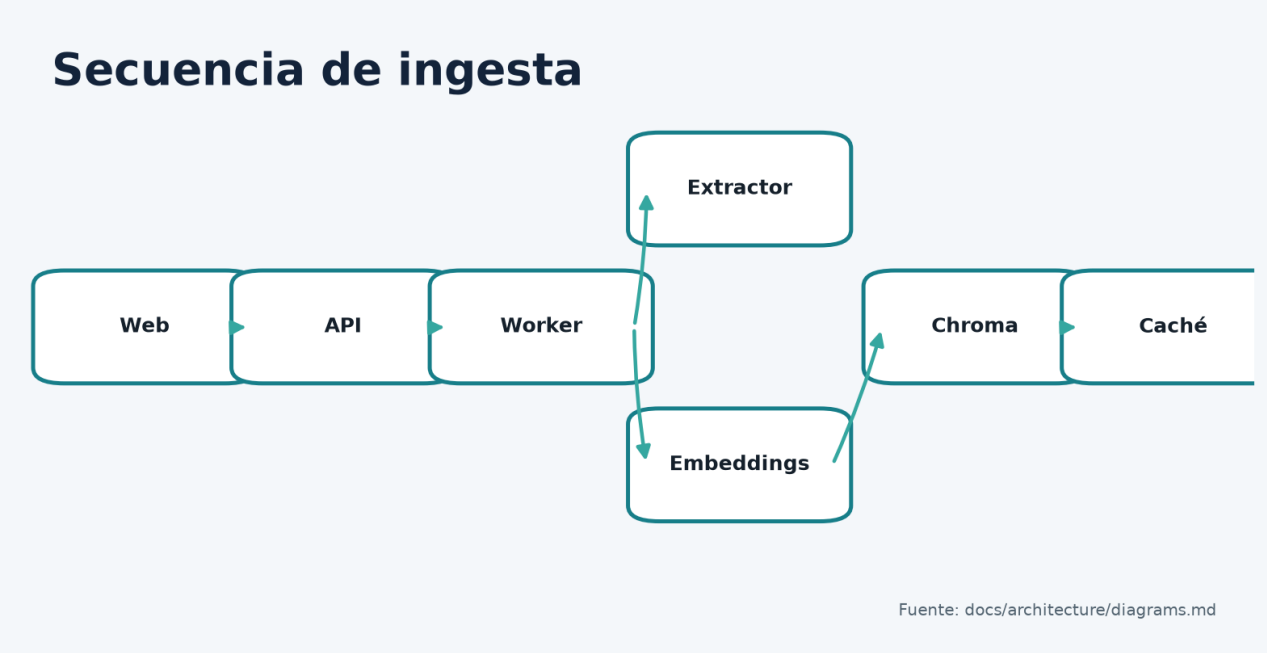


Figura 6. Secuencia de ingesta, embeddings, publicación e invalidación.

La publicación es atómica: se extrae, fragmenta, incrusta y construye una nueva generación antes de hacerla activa. El cambio de snapshot invalida las respuestas dependientes del corpus anterior.

5.2 Consulta normal

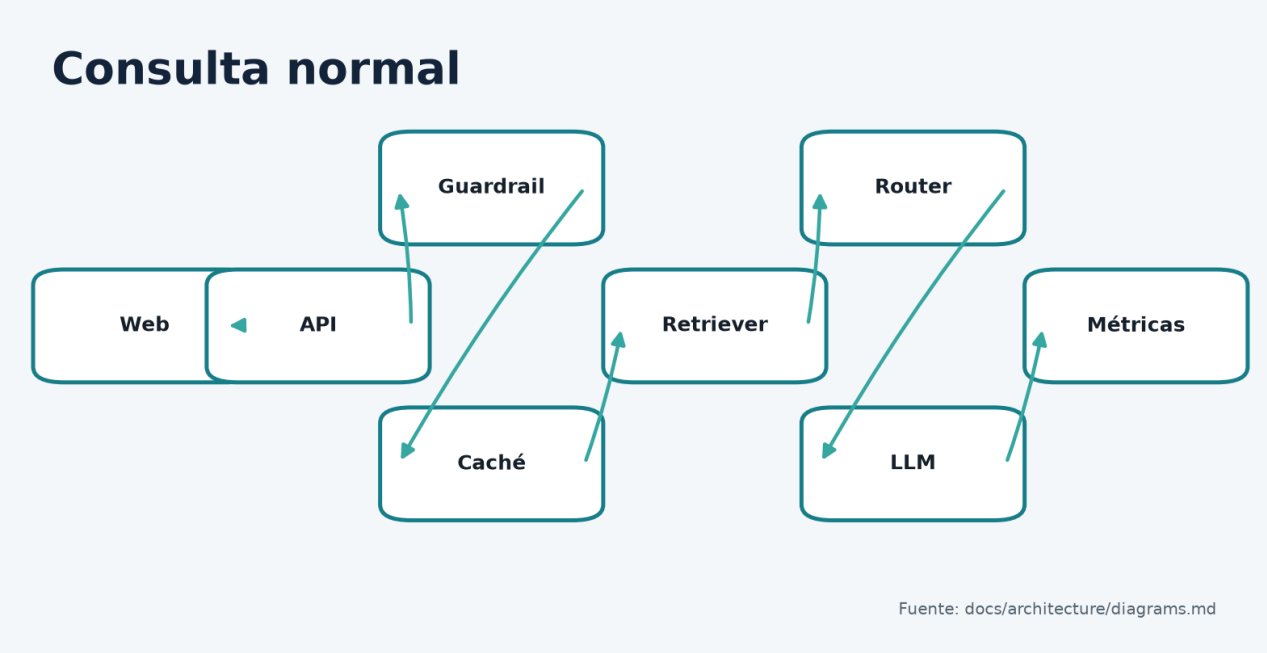


Figura 7. Recorrido de una consulta normal.

La consulta se valida, atraviesa guardrails, consulta caché, recupera evidencia, selecciona ruta y modelo, genera, verifica salida y registra métricas. La respuesta incluye fuentes, modelo, caché y traza.

5.3 Consulta desde caché

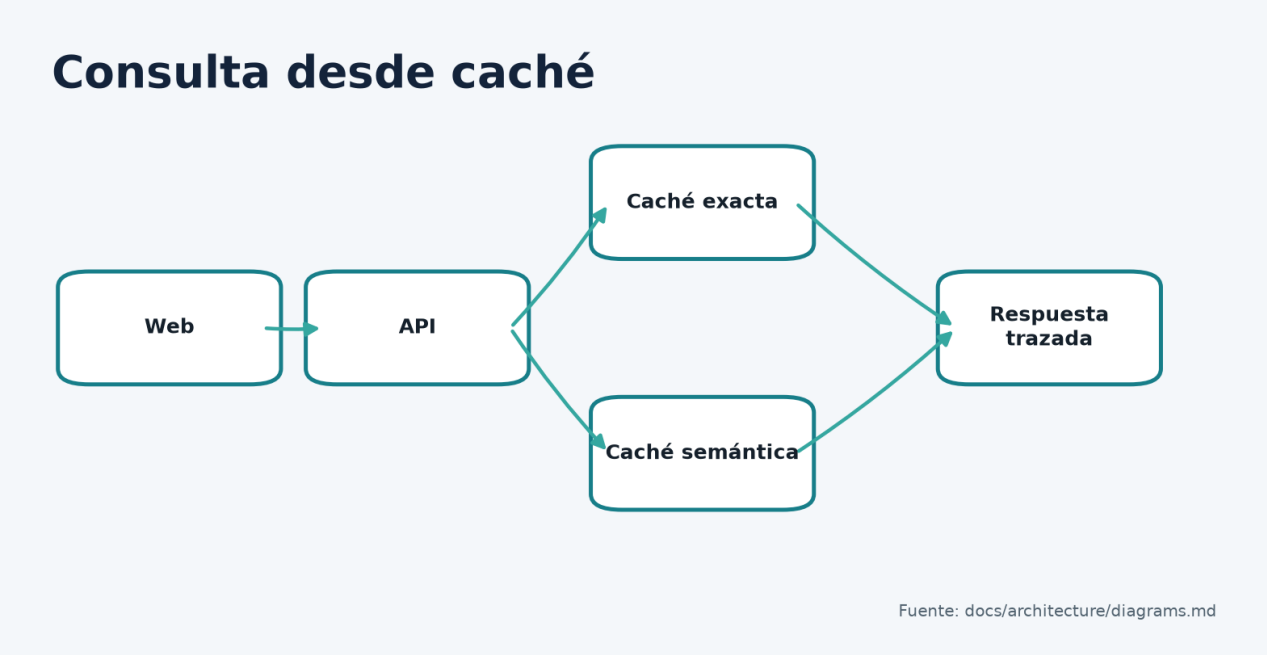


Figura 8. Respuesta desde caché exacta o semántica.

La caché exacta usa una identidad estructural; la semántica compara embeddings dentro de la misma partición y exige similitud de 0.85. El snapshot participa en la identidad para evitar evidencia obsoleta.

5.4 Consulta bloqueada

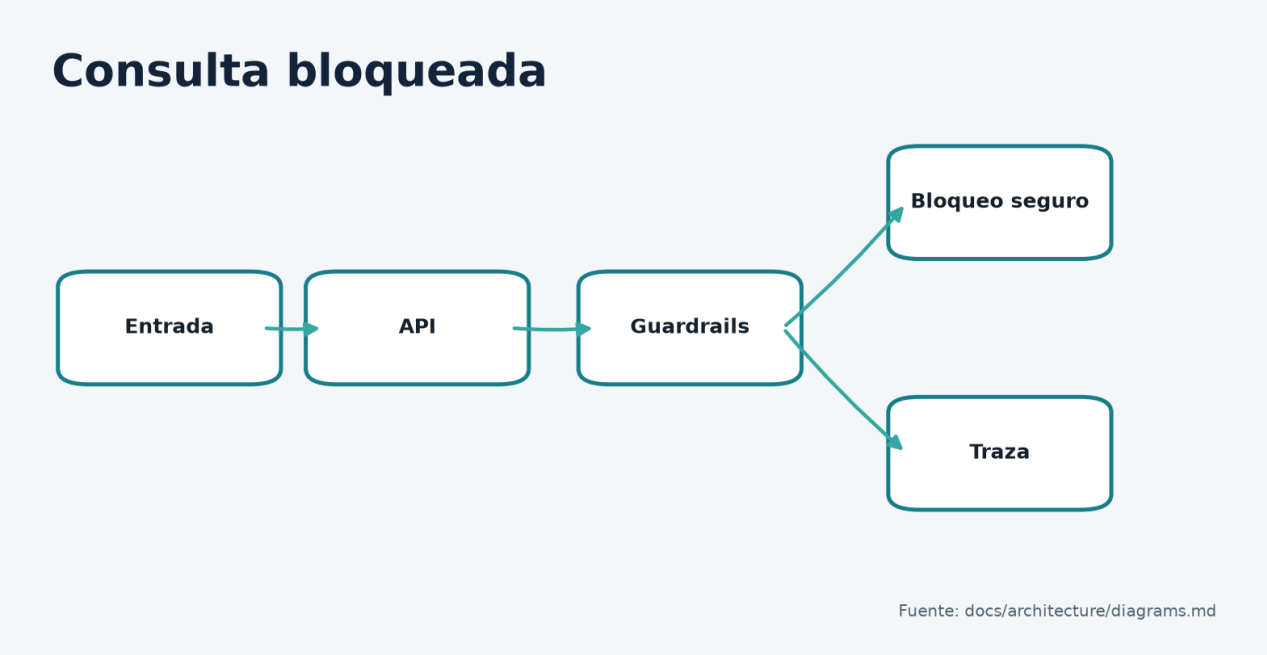


Figura 9. Bloqueo de entrada y respuesta segura.

La cadena de entrada detecta inyección de instrucciones, fuera de dominio, datos sensibles y forma inválida. Un rechazo termina antes de recuperar o llamar al modelo y queda ligado a la traza.

5.5 Ciclo de agente

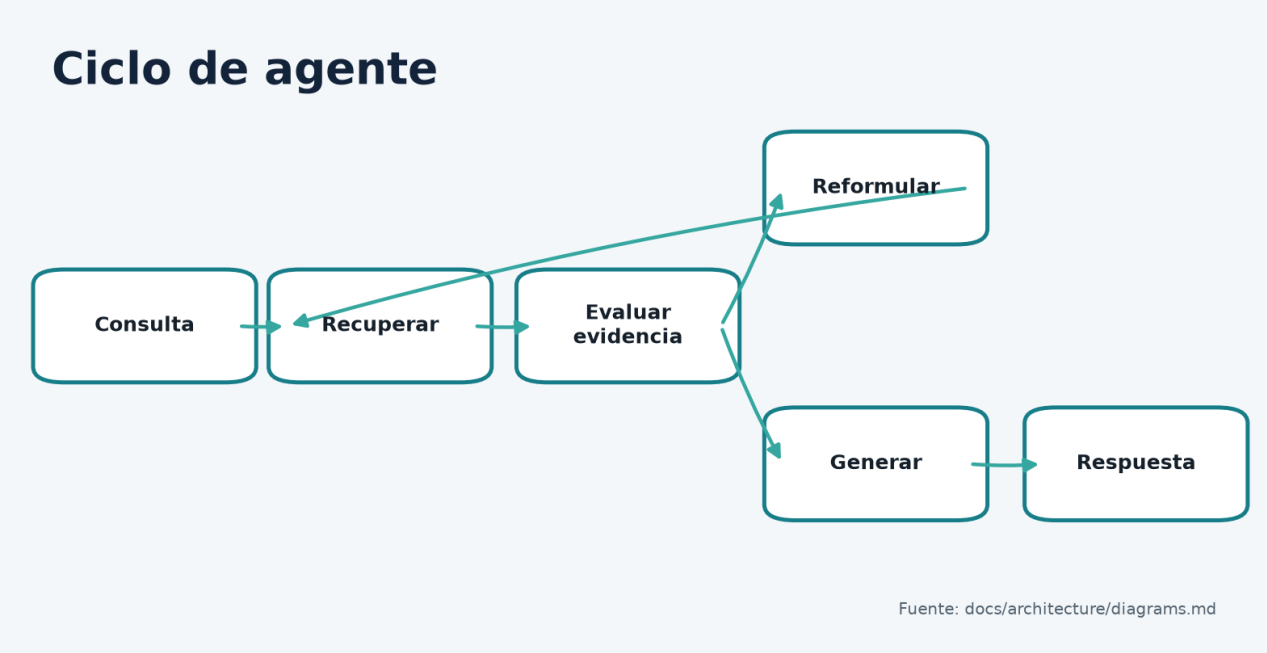


Figura 10. Ciclo recuperar–evaluar–reformular.

Cuando la evidencia inicial es insuficiente, el orquestador conserva el dominio, reformula y recupera de nuevo. El ciclo termina tras un máximo de dos iteraciones; si persiste la insuficiencia, el sistema se abstiene.

6. Selección de modelos y enrutamiento

6.1 Modelos de lenguaje

Criterio	llama3.2:3b	qwen3.5:2b
Parámetros / cuantización	3.2 B / Q4_K_M	2.2 B / MXFP8
Precisión de cita	0.634	0.708
Salida estructurada	1.00	0.90
Falsas abstenciones	0.20	0.40
p50 / p95	5.08 / 8.23 s	3.68 / 7.82 s
Memoria cargado	3.1 GB	4.7 GB
Licencia	Llama Community	Apache 2.0

La asignación permanece provisional porque ningún modelo supera G1 = 0.80. Llama se usa en simple y fallback por consistencia; Qwen en complex por latencia y citas, sin permitir que el LLM altere la puntuación determinista.

6.2 Embeddings

Criterio	Nomic	BGE-M3
Dimensiones	768	1024
Recall@1 / @3 / @5	0.575 / 0.925 / 0.925	0.625 / 0.900 / 0.925
Hit@5	0.950	0.950
MRR	0.808	0.825
Tiempo embeddings	16.1 s	34.4 s
Tamaño	274 MB	1.2 GB

Se mantiene Nomic porque empata en Recall@5 e Hit@5, supera a BGE-M3 en Recall@3 y reduce tiempo y almacenamiento. Los umbrales de similitud no son transferibles entre modelos.

7. Diseño de las capas

Capa	Responsabilidad	Evidencia
C1 API	HTTP, esquemas, errores	FastAPI/OpenAPI
C2 Orquestación	flujo y agente	máx. 2 iteraciones
C3 Guardrails	entrada/salida	detección 1.0
C4 Caché	exacta/semántica	umbral 0.85
C5 Contexto	RAG y prompt	Recall@5 0.925
C6 Router/Gateway	ruta, timeout, fallback	router 1.0
C7 Acceso	adaptadores locales	puertos/interfaces
T1 Observabilidad	trazas y métricas	por capa
T2 Feedback	utilidad/comentario	ligado a traza

7.1 Políticas clave

- Top-k 6 y máximo dos fragmentos por sección.
- Router complex si hubo reformulación, >2 razas, >3 criterios o >6 fragmentos.
- Timeout de 120 s, reintento transitorio y fallback exclusivamente local.
- Puntuación y orden deterministas; narrativa opcional no altera la decisión.

8. Registro de decisiones de arquitectura

ADR	Decisión	Estado / consecuencia
01	Fragmentación por página y sección	Aceptada; citas directas
02	Router determinista simple/complex	Aceptada; auditable
03	Caché semántica 0.85	Aceptada con riesgo
04	Guardrails en código	Aceptada
05	Agente acotado	Aceptada
06	Chroma por generaciones + SQLite	Aceptada
07	Alias de LLM	Provisional: G1
08	Nomic frente a BGE-M3	Aceptada
09	Puntuación determinista	Aceptada

Las alternativas descartadas incluyen un clasificador LLM para enrutamiento, un único modelo, umbrales compartidos entre embeddings, publicación no atómica y puntuación decidida por el modelo. El criterio común fue privilegiar auditabilidad, operación local y degradación segura.

8.1 Consecuencias transversales

- La explicabilidad depende de conservar metadatos y versiones.
- Cambiar embeddings exige una generación nueva y recalibrar umbrales.
- El chat hereda la limitación de citas de los LLM; BreedMatch reduce impacto con lógica determinista.
- La caché acelera, pero exige particiones e invalidación estrictas.

9. Evaluación

Componente	Métrica	Resultado	Estado
Recuperación	Recall@5 / Hit@5	0.925 / 0.950	cumple
Citas Llama	precisión	0.634	no cumple G1
Citas Qwen	precisión	0.708	no cumple G1
Guardrails	detección / FP	1.0 / 0.0	cumple
Router	exactitud	1.0	cumple
Caché	indebidas	0	cumple
Agente	terminación	1.0	cumple
BreedMatch	orden/estado/hallazgos	1.0	cumple
Citas BreedMatch	páginas esperadas	0.93	cumple



Figura 11. Comparación de generación y recuperación.

9.1 Análisis de errores

La evaluación encontró falsos bloqueos en el guardrail de dominio, negaciones mal interpretadas, alcance incorrecto de «nunca» y sustitución de evidencia durante la reformulación. Las correcciones conservaron datasets y puertas para permitir comparación.

El déficit principal permanece en precisión de citas del chat. Algunas páginas adyacentes son pertinentes pero no estaban etiquetadas como aceptables; otras respuestas contienen citas realmente irrelevantes o síntesis vacías. La revisión humana debe distinguir ambos casos sin relajar retrospectivamente la puerta.

9.2 Con y sin RAG

Indicador	Sin RAG	Con RAG
Citas	ninguna	verificables
Abstención correcta	0.50	1.00
Falsas abstenciones	0.60	0.20
p50	0.53 s	5.08 s

RAG aumenta latencia, pero reduce invenciones y mejora abstención. La caché recupera parte de ese costo: en el ensayo local la repetición bajó de 13.3 s a 20 ms; es una observación de ensayo, no un promedio del dataset.

10. Limitaciones, riesgos y trabajo futuro

Limitación	Riesgo	Trabajo futuro
Citas del chat < 0.80	fundamentación incorrecta	revisión humana y prompts
Sin validación especialista	recomendación inadecuada	evaluación independiente
Extracción automática	afirmaciones erróneas	muestreo y veto
Umbrales por modelo	abstención o pase incorrecto	calibración separada
Ensayo offline pendiente	falla en defensa	preflight y plan B
Corpus con derechos	redistribución indebida	confirmar permiso

10.1 Lineamientos éticos

- Advertir que el contenido es generado y puede contener errores.
- No presentar recomendaciones como consejo veterinario.
- No incluir datos personales o sensibles en corpus y trazas.
- Declarar el uso de asistentes de IA y revisar el contenido final.

10.2 Uso declarado de IA

Se utilizaron asistentes de IA para apoyar especificaciones, implementación, pruebas, borradores de ADR, diagramas, datasets y redacción de estos entregables. Las etiquetas asistidas requieren firma humana antes de presentarse como revisión independiente. El producto ejecutado no consume modelos en la nube.

11. Referencias

De Giuliani, C. (2019). Enciclopedia de los perros de caza. Editorial De Vecchi.

Proyecto integrador: producto inteligente en capas con modelos de lenguaje, embeddings y RAG. Unidad II, 2026.

Repositorio K9 Expert: README, diagramas, ADR, evaluación y matriz de trazabilidad.

Ollama. Documentación de ejecución local de modelos.

FastAPI, Chroma y React. Documentación de las tecnologías utilizadas.

12. Anexos

12.1 Reproducción

El README contiene instalación, descarga de modelos, ingesta, preflight, ejecución, API y pruebas. La documentación OpenAPI se sirve en http://127.0.0.1:8000/docs.

12.2 Evidencia y endpoints

Recurso	Ubicación
Diagramas	docs/architecture/diagrams.md
ADR	docs/adr/
Evaluación	docs/evaluation/ y evaluation/runs/
Trazabilidad	docs/rubric/traceability.md
Operación	docs/operations/local-operations.md
API	/docs y /openapi.json

12.3 Datos por completar

- Nombre del alumno, institución y docente.
- Confirmación de permiso del corpus.
- Firma de revisión humana y ficha aprobada.
- Resultado del ensayo final sin conexión.