K9 BREEDMATCH

Recomendación explicable de perros de caza

Embeddings · RAG · arquitectura local en capas

[NOMBRE DEL ALUMNO] · Tópicos selectos de arquitectura de software

Una decisión, no una conversación

PROBLEMA Y PROPUESTA

Usuario concreto: cazador que debe elegir una raza para una tarea.

Entrada: presa, modalidad de trabajo y terreno.

Salida: razas priorizadas, compatibilidad, cobertura y citas por página.

Valor: reducir una revisión experta extensa a una recomendación verificable.

Experiencia guiada

FLUJO DEL USUARIO

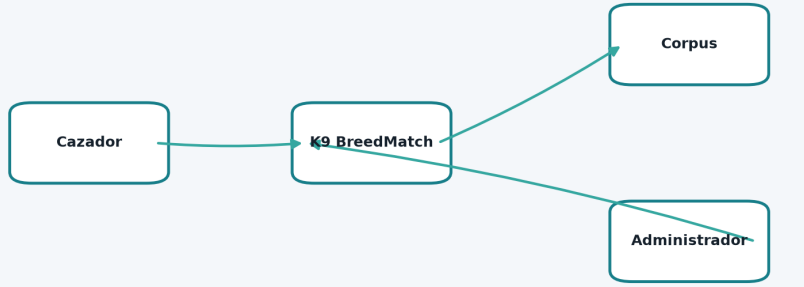
1 Perfil de caza en tres pasos

2 Comparación determinista y cobertura de evidencia

3 Recomendación con advertencias y fuentes

4 Retroalimentación ligada a la traza

Contexto



Fuente: docs/architecture/diagrams.md

Todo ocurre en la Mac

ARQUITECTURA LOCAL

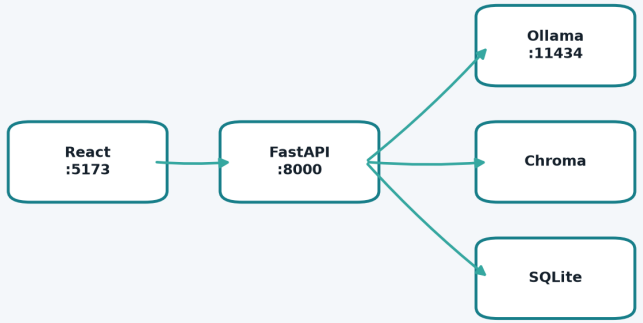
React consume exclusivamente la API por HTTP.

FastAPI organiza la lógica y expone OpenAPI.

Ollama sirve LLM y embeddings sin nube.

Chroma almacena vectores; SQLite conserva trazas, caché y feedback.

Contenedores



Fuente: docs/architecture/diagrams.md

Capas con responsabilidades verificables

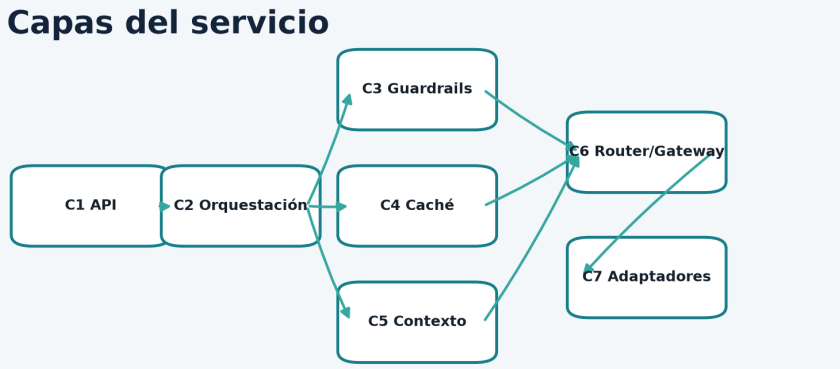
C1–C7 · T1–T2

C1–C2: API y orquestación

C3–C4: guardrails y caché

C5–C6: contexto RAG, router y gateway

C7: adaptadores; T1/T2: observabilidad y feedback



Fuente: docs/architecture/diagrams.md

RAG: de 243 páginas a evidencia

CONSTRUCCIÓN DE CONTEXTO

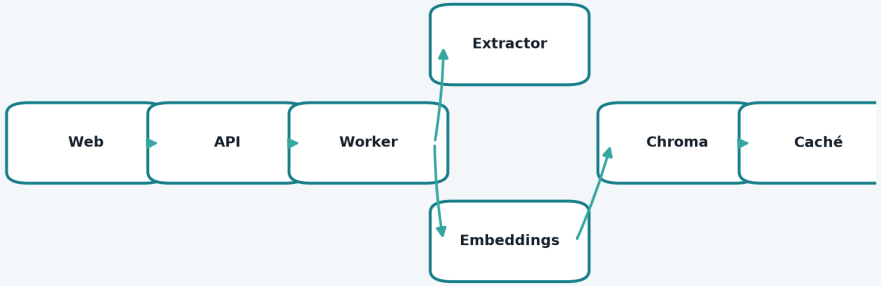
Extracción y fragmentación por página/sección.

786 fragmentos con metadatos y generación de índice atómica.

Top-k 6, máximo 2 fragmentos por sección.

Recall@5 0.925 · Hit@5 0.950 · MRR 0.808.

Secuencia de ingesta



Fuente: docs/architecture/diagrams.md

Dos LLM, dos compromisos

EVIDENCIA MEDIDA

Criterio	Llama 3.2 3B	Qwen 3.5 2B
Ruta	simple / fallback	complex
Citas	0.634	0.708
Salida estructurada	1.00	0.90
Falsas abstenciones	0.20	0.40
p50	5.08 s	3.68 s
Estado	provisional	provisional

Embeddings: gana el equilibrio

EVIDENCIA MEDIDA

Criterio	Nomic	BGE-M3
Dimensiones	768	1024
Recall@1	0.575	0.625
Recall@5	0.925	0.925
Hit@5	0.950	0.950
MRR	0.808	0.825
Tiempo embeddings	16.1 s	34.4 s
Tamaño	274 MB	1.2 GB

Control antes, durante y después

GUARDRAILS · CACHÉ · AGENTE

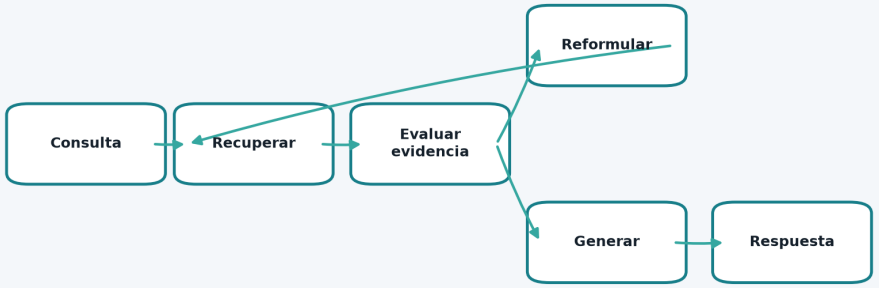
Entrada: inyección, dominio, datos sensibles y forma.

Caché exacta y semántica, umbral 0.85 e invalidación por snapshot.

Agente acotado: recuperar → evaluar → reformular (máx. 2).

Salida: formato, citas, contexto y respuesta segura.

Ciclo de agente



Fuente: docs/architecture/diagrams.md

Demostración local · 5 minutos

RUTA PRINCIPAL

0:00 Salud del sistema y perfil guiado

1:00 Recomendación, cobertura y cita

2:10 Repetición desde caché

2:45 Entrada bloqueada

3:20 Ciclo de agente y retroalimentación

4:20 Métricas y OpenAPI

Resultados por capa

EVIDENCIA MEDIDA

Componente	Resultado	Lectura
Guardrails	1.0 / FP 0.0	cumple
Router	exactitud 1.0	cumple
Caché	13.3 s → 20 ms	observado
Agente	terminación 1.0	cumple
BreedMatch	orden/estado 1.0	cumple
Páginas citadas	0.93	cumple

Lo que funciona y lo que falta

CONCLUSIÓN

Fortaleza: decisión determinista, fuentes, operación local y trazabilidad.

Pendiente: precisión de citas del chat < 0.80.

Pendiente: revisión humana, validación especialista y ensayo sin conexión.

Siguiente paso: ampliar dataset, revisar evidencia y medir concurrencia.

Una recomendación útil también debe poder explicar sus límites.