K9 BREEDMATCH

Decisión explicable para perros de caza

Arquitectura local · embeddings · RAG · evidencia por página

Guillermo Tinoco Ramos· Tópicos selectos de arquitectura de software

Una decisión, no una conversación

Momento

Un cazador elige raza para una presa, modalidad y terreno concretos.

Resultado

Top de razas, compatibilidad, cobertura, conflictos y citas por página.

Prueba anti-chatbot

Sin chat, el motor determinista y la evidencia siguen resolviendo la tarea principal.

Caso conductor · venado + trabajo de rastro + monte · sólo valores admitidos por la aplicación

El valor se conserva sin el chat

1 · Perfil

Presa, función y terreno se traducen a dimensiones controladas.

2 · Decisión

Reglas versionadas calculan compatibilidad y orden; el LLM no cambia el ranking.

3 · Evidencia

Cobertura y citas distinguen lo documentado de lo desconocido.

4 · Mejora

Feedback queda ligado a traza, modelo y resultado.

Valor medible: consistencia del orden · cobertura · páginas esperadas · utilidad · latencia

Corpus propio, trazable y con límites

243 páginas

Enciclopedia de los perros de caza · español · PDF.

786 fragmentos

Página, sección, documento y raza preservados en metadatos.

Condición de uso

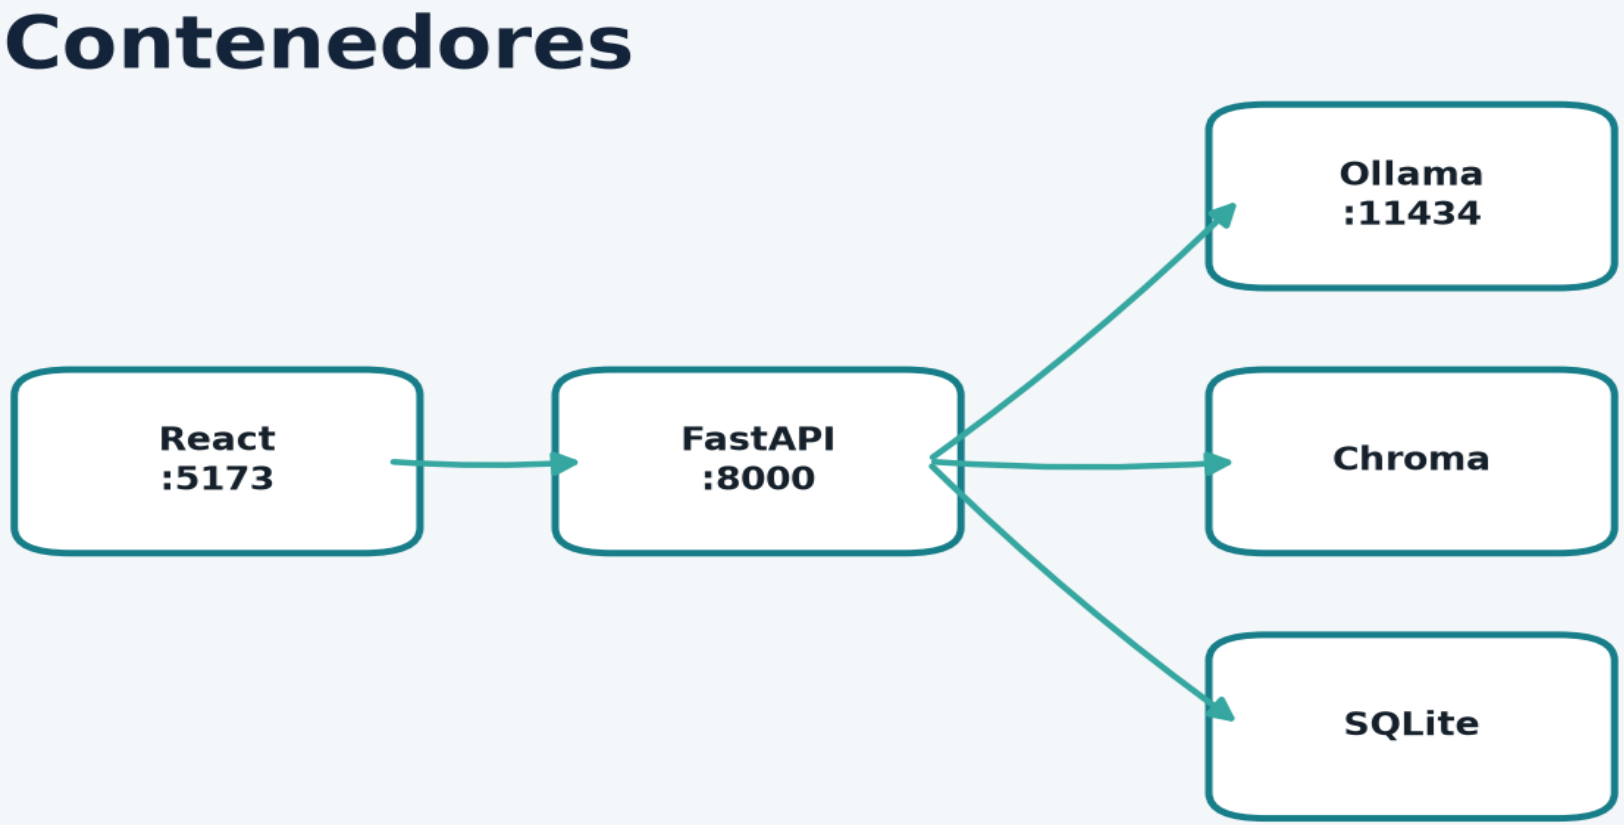
Derechos de autor: no redistribuir. Permiso académico por confirmar.

Originalidad: unir decisión determinista + recuperación documental + explicación acotada

Cinco vistas responden cinco preguntas

Vista	Pregunta	Uso en defensa
1 Contexto	¿Quién usa el sistema y qué queda fuera?	Producto
2 Contenedores	¿Qué procesos y almacenes colaboran?	Ruta principal
3 Capas	¿Dónde vive cada responsabilidad?	Ruta principal
4 Componentes	¿Qué módulos e interfaces realizan el trabajo?	Apéndice
5 Despliegue	¿Dónde corre y por qué es local?	Ruta principal

Contenedores: la web sólo conoce HTTP



Fuente: docs/architecture/diagrams.md

Figura 2 · React → FastAPI por HTTP; Ollama, Chroma, SQLite y archivos quedan detrás del servicio.

RAG empieza antes de la consulta

PDF

Extracción PyMuPDF; OCR sólo cuando aplica.

Fragmento

Unidad por página/sección con solapamiento lógico y metadatos.

Embedding

Vector numérico de significado; no genera texto.

Índice

Nomic 768d → Chroma; publicación por generación atómica.

Cambio de modelo ⇒ regenerar índice + recalibrar umbrales

Recuperar, decidir y sólo después redactar

1 · Representar

Consulta → embedding con el mismo modelo del índice.

2 · Recuperar

k=6; máximo 2 fragmentos por sección; filtros inmutables.

3 · Decidir

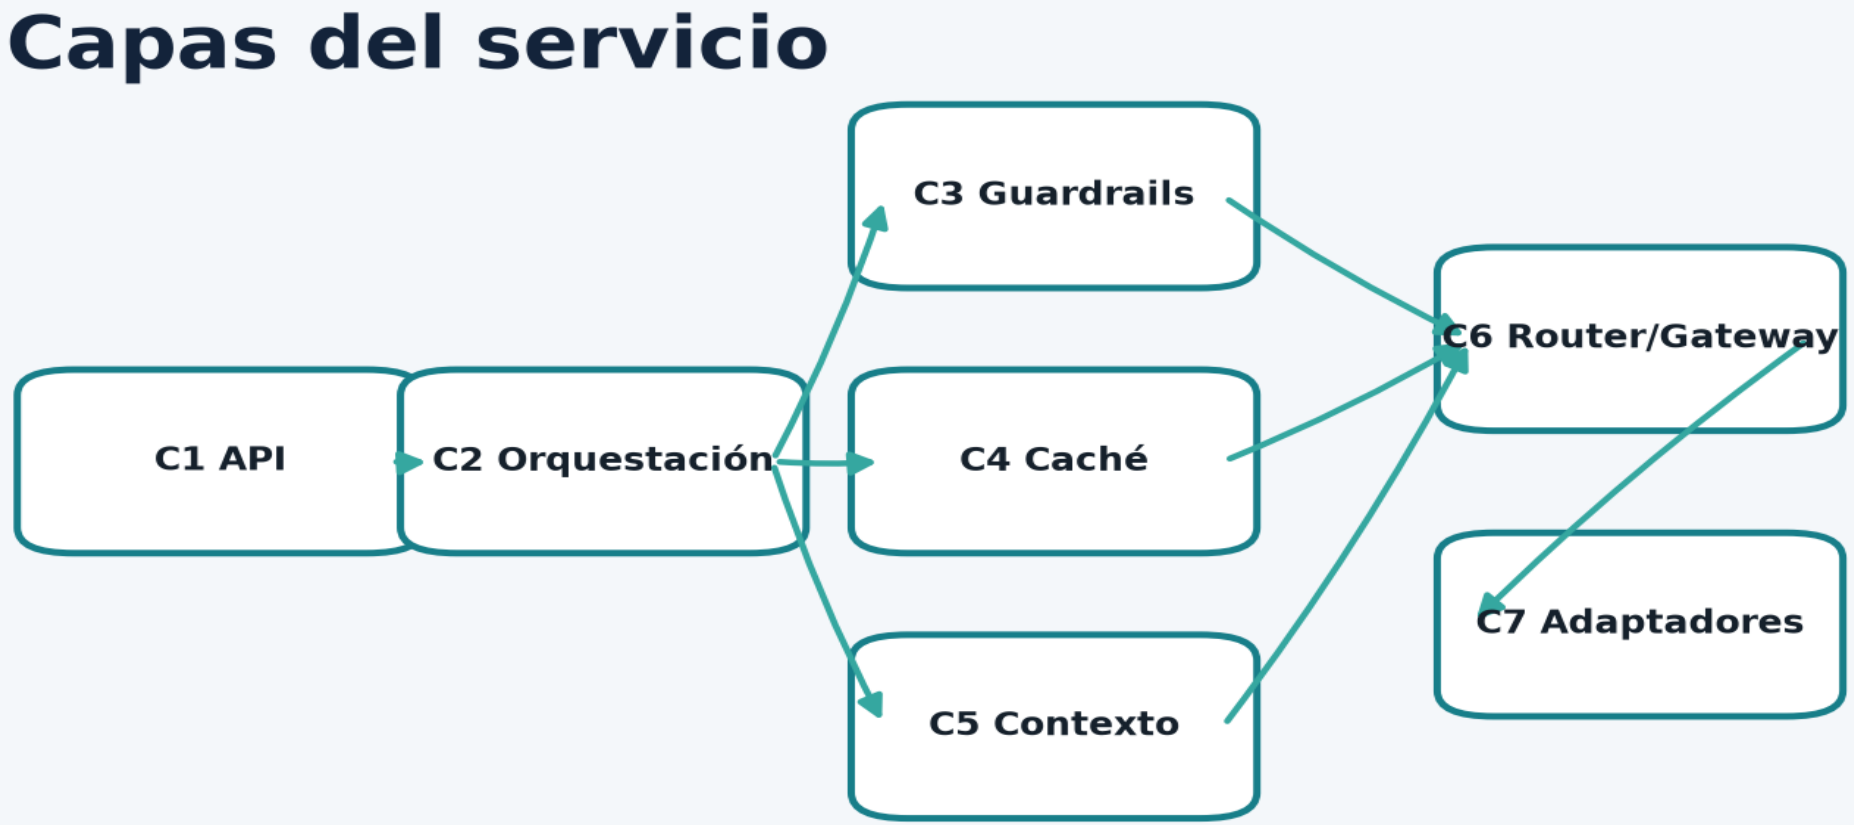
Matcher determinista produce match / mismatch / no documentado.

4 · Redactar

Prompt usa hallazgos + evidence_ids; salida valida citas.

Evidencia insuficiente → reformular hasta 2 iteraciones o abstenerse

Capas: dependencia estática ≠ orden de ejecución



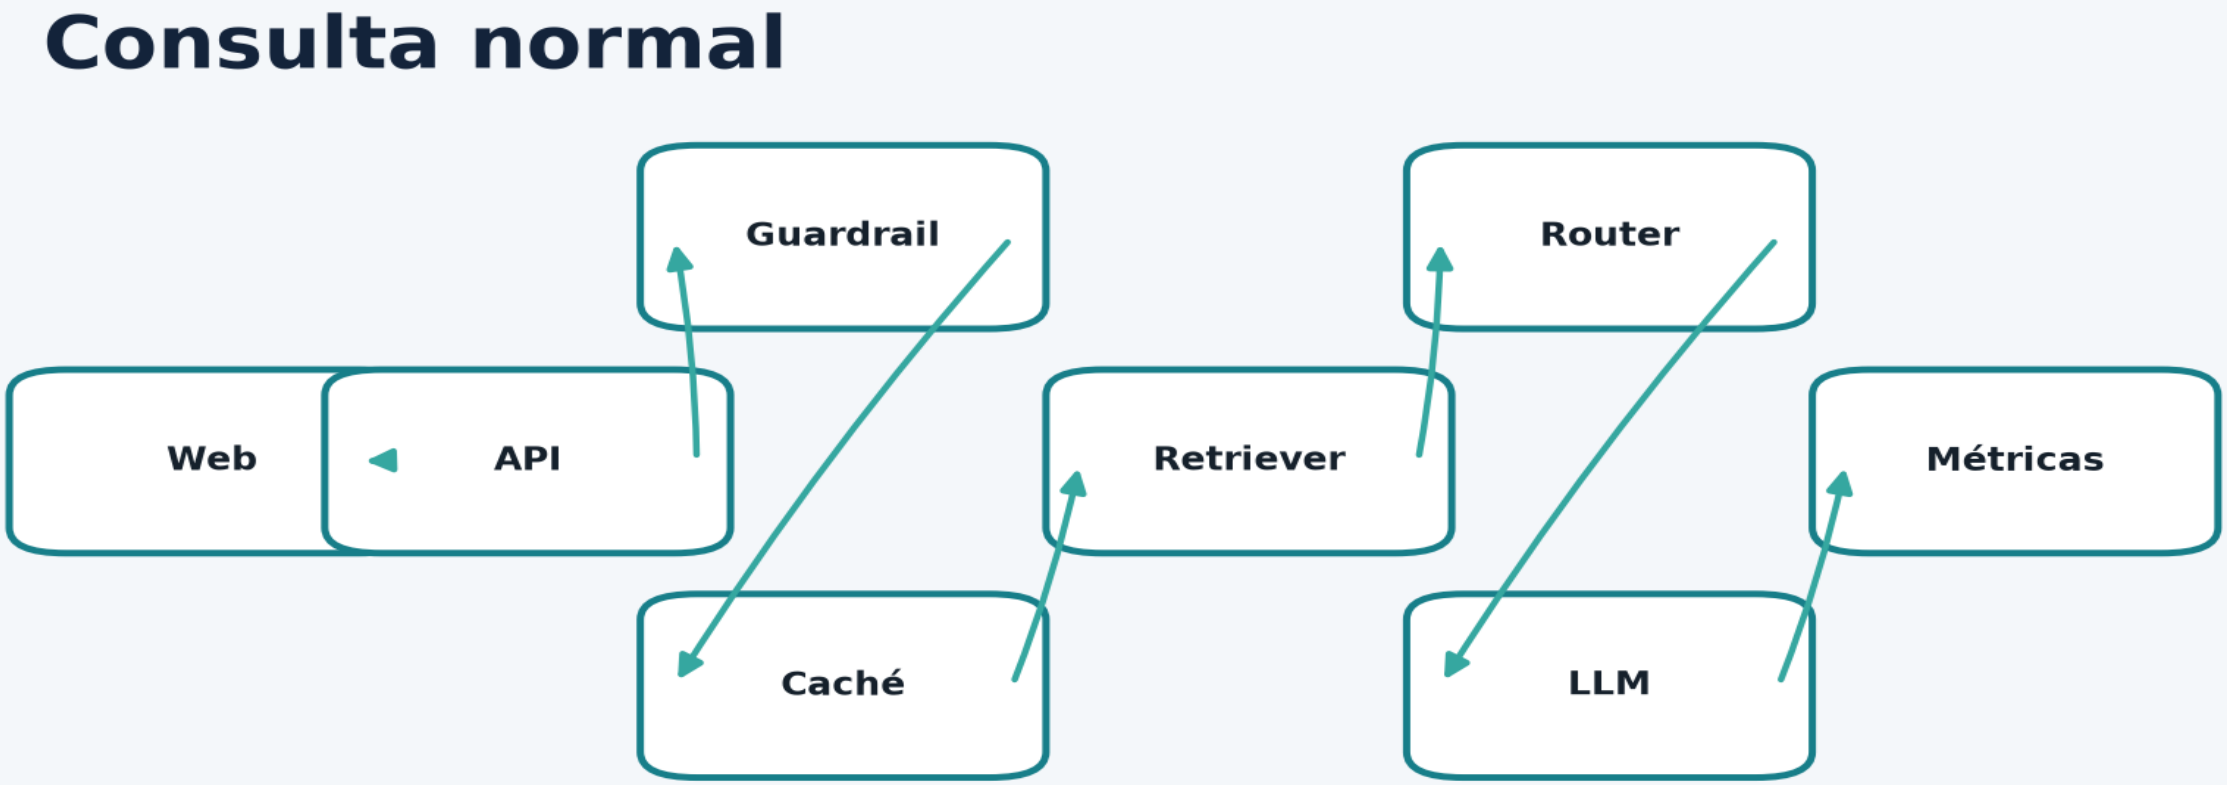
Fuente: docs/architecture/diagrams.md

Figura 3 · C1–C7 dependen hacia abajo; T1/T2 cruzan el flujo. La secuencia temporal se muestra aparte.

La arquitectura existe en módulos reales

Capa	Módulos principales	Responsabilidad
C1	presentation/api.py	HTTP, validación, OpenAPI
C2	query.py · breed_analysis.py · agent.py	orquestar y reformular
C3	guardrails.py · generation.py	entrada, salida, citas
C4	response_cache.py	exacta, semántica, TTL
C5	indexing.py · breed_match.py	recuperar, contexto, ranking
C6	routing.py · generation.py	ruta, gateway, fallback
C7	infrastructure/* · ports/*	SQLite, Chroma, Ollama, archivos
T1/T2	observability.py · interactions.py	traza, métricas, feedback

Solicitud normal: diez pasos observables



Fuente: docs/architecture/diagrams.md

Figura 7 · Validar → trazar → guardrails → caché → recuperar → enrutar → generar → validar → persistir → feedback.

Dos LLM: ninguno gana todo

Criterio	Llama 3.2 3B	Qwen 3.5 2B
Ruta	simple / fallback	complex
Precisión de citas	0.634	0.708
Salida estructurada	1.00	0.90
Falsas abstenciones	0.20	0.40
p50 / p95	5.08 / 8.23 s	3.68 / 7.82 s
Memoria / cuantización	3.1 GB · Q4_K_M	4.7 GB · MXFP8
Licencia	Llama Community	Apache 2.0
Estado	provisional: G1 < 0.80	provisional: G1 < 0.80

Nomic gana por equilibrio, no por MRR

Criterio	Nomic	BGE-M3
Dimensiones	768	1024
Recall@1 / @3 / @5	.575 / .925 / .925	.625 / .900 / .925
Hit@5 / MRR	.950 / .808	.950 / .825
Embeddings del corpus	16.1 s	34.4 s
Tamaño	274 MB	1.2 GB
Decisión	activo	alternativa medida

Beneficio: mismo Recall@5/Hit@5 con menor costo · Sacrificio: −0.017 MRR y −0.050 Recall@1

Control antes, durante y después

Entrada

Inyección, dominio, datos sensibles y forma. Bloquea antes de recuperar/generar.

Caché

Exacta + semántica 0.85; TTL y snapshot. Revalida la salida reutilizada.

Gateway

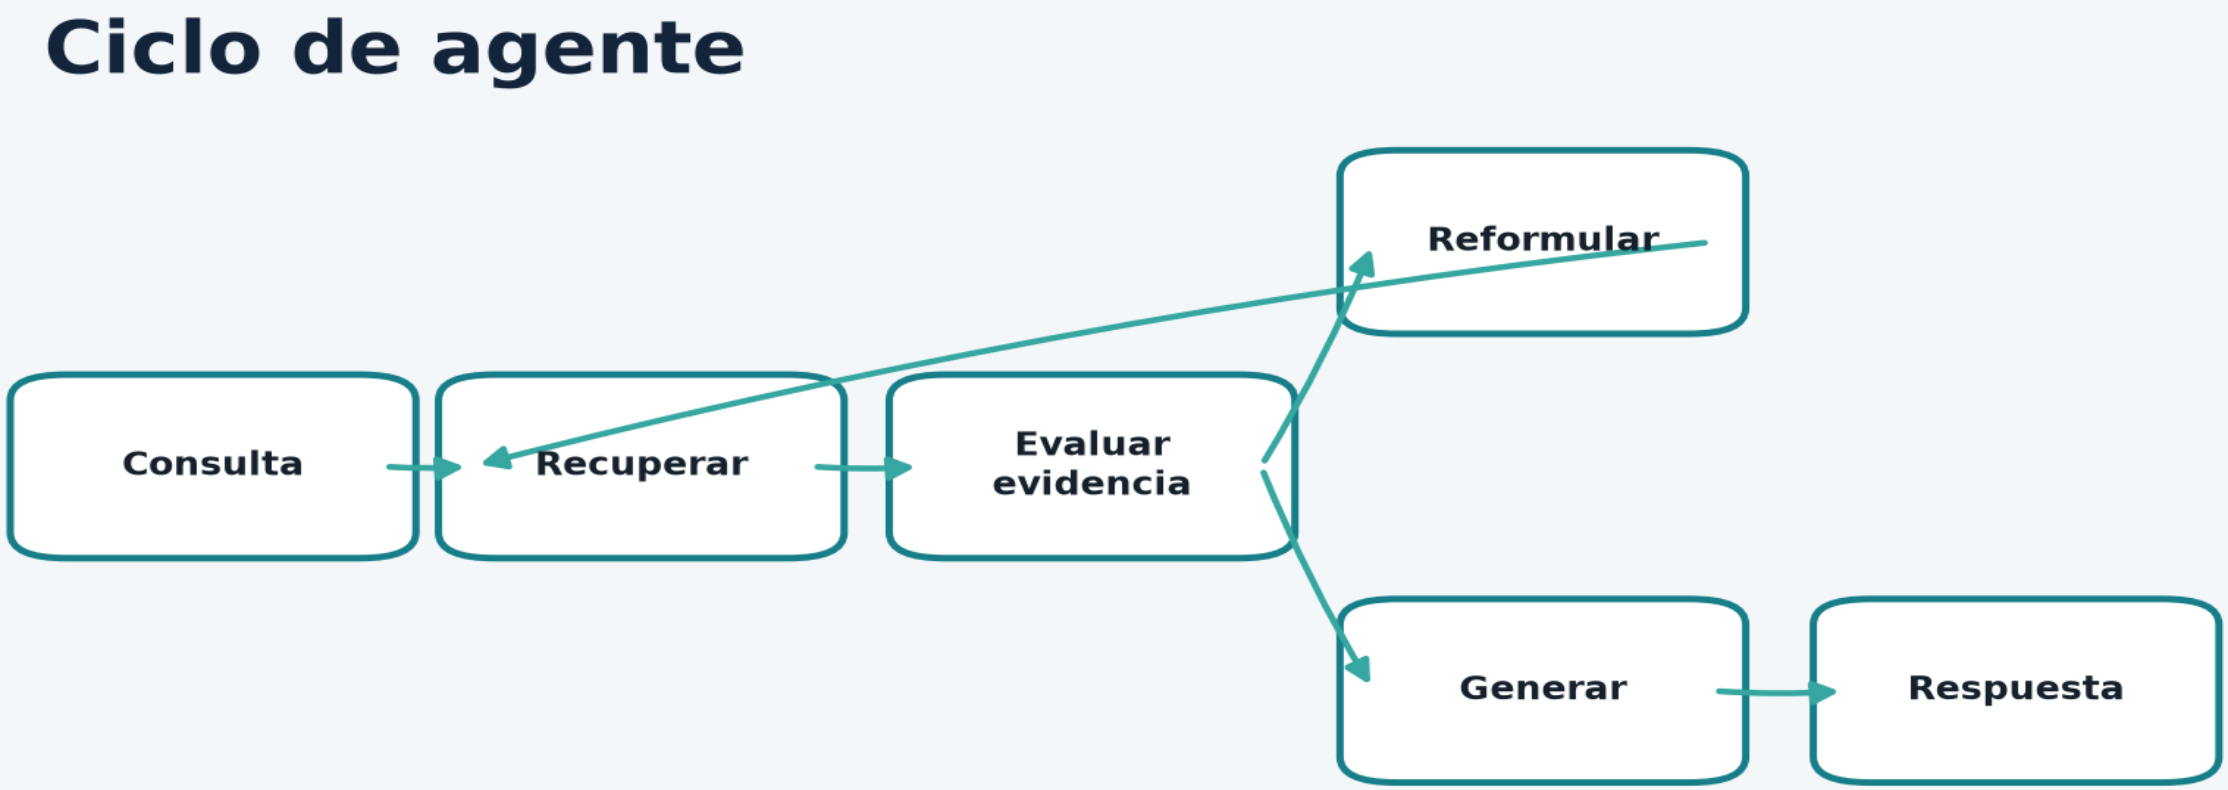
Timeout 120 s, reintento transitorio y fallback local configurado.

Salida

Esquema, razas y evidence_ids; responder seguro si falla.

Riesgo residual: falsos positivos/negativos y reutilización semántica incorrecta fuera del dataset

Agente: un ciclo con condición terminal



Fuente: docs/architecture/diagrams.md

Figura 10 · Recuperar → evaluar → reformular → recuperar; máx. 2. Si sigue débil, abstención sin generación.

Demostración local · 5 minutos

Tiempo	Acción	Señal observable
0:00	salud + cargar PDF pequeño	job available + invalidación
1:05	BreedMatch con venado/monte	ranking + citas + trace_id
2:05	repetir + paráfrasis	exact hit + semantic hit
2:45	inyección	rejected; generation=false
3:05	evidencia débil	iteración o abstención
3:40	feedback + métricas	vínculo a traza y capas
4:35	OpenAPI	frontera `/api/v1`

Resultados por capa, no una sola precisión

Capa	Métrica	Resultado	Lectura
Recuperación	Recall@5 / Hit@5	.925 / .950	cumple
Chat Llama / Qwen	precisión de citas	.634 / .708	no cumple G1
Guardrails	detección / FP	1.0 / 0.0	dataset acotado
Router	exactitud	1.0	dataset etiquetado
Caché	reuso indebido	0	casos repetidos/paráfrasis
Agente	terminación	1.0	máx. 2
BreedMatch	páginas esperadas	.93	producto principal

El diseño gana auditabilidad y paga latencia

RAG

+ citas y abstención
− p50 5.08 s vs 0.53 s sin RAG

Local

+ privacidad y costo marginal
− recursos y arranque

Determinista

+ reproducibilidad
− vocabulario controlado

Caché

+ 13.3 s → 20 ms observado
− riesgo de reuso incorrecto

Observación de caché ≠ promedio del dataset · comparación conceptual ≠ alternativa experimentada

Conclusión

Una recomendación útil también explica sus límites.

Demostrado

Decisión determinista, arquitectura local, evidencia por página y trazas.

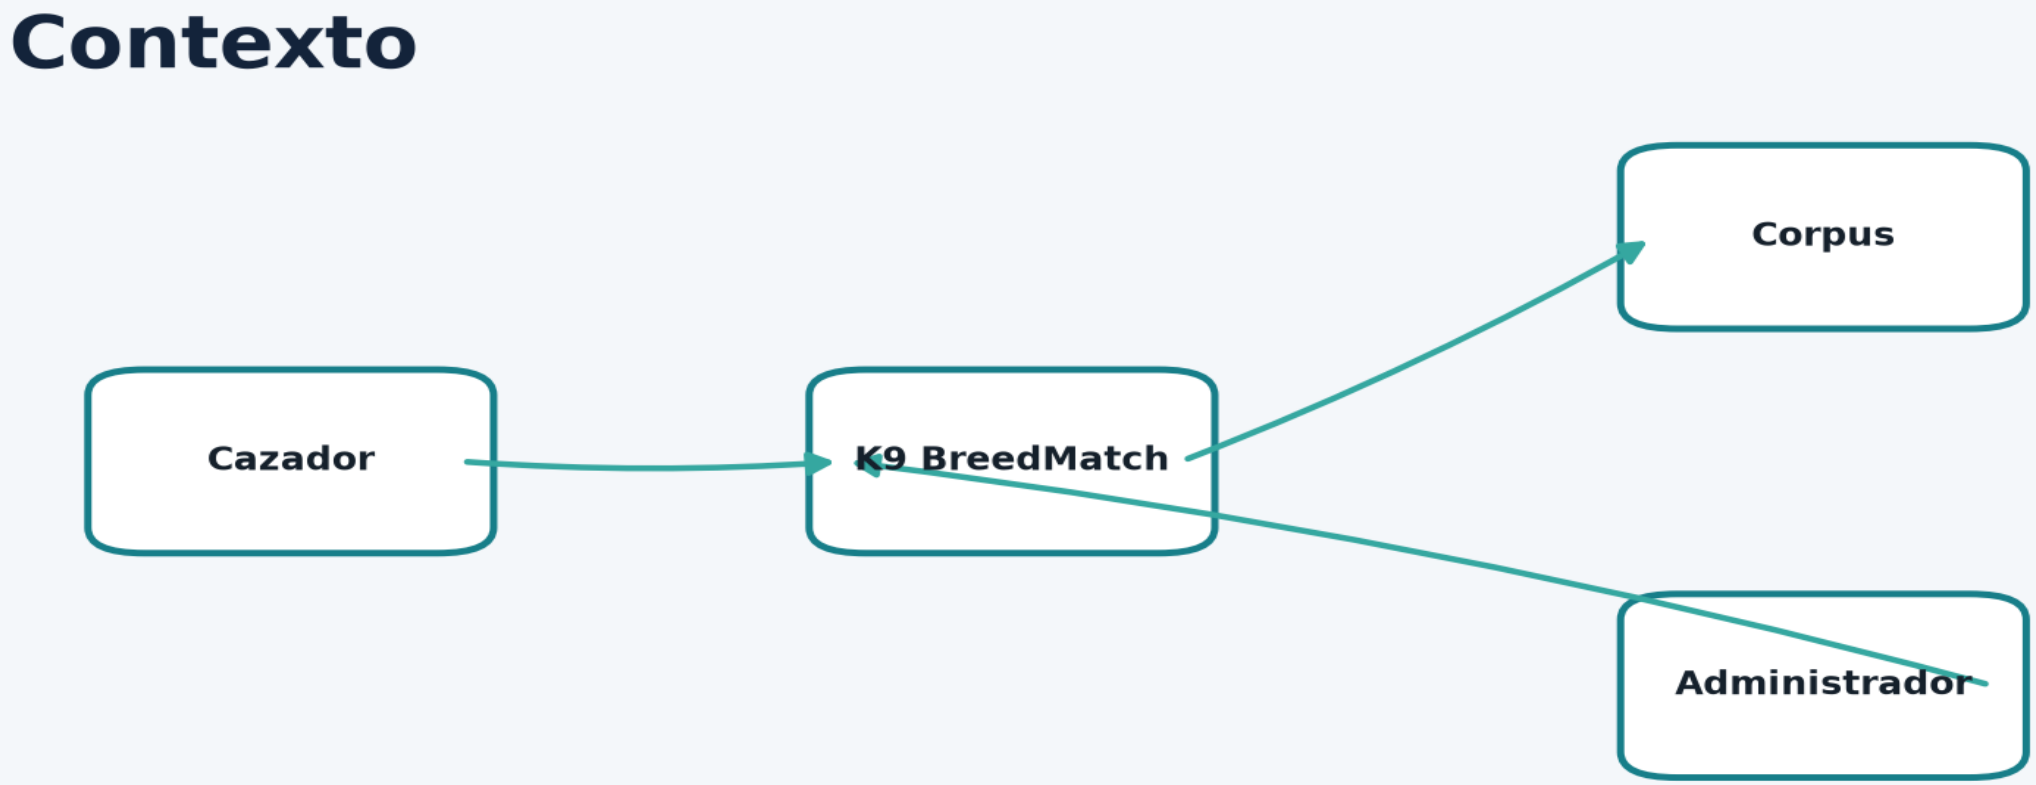
No demostrado

G1 del chat, validación especialista, revisión humana y ensayo offline final.

Siguiente

Ampliar dataset, firmar revisión, calibrar por modelo y probar clon limpio.

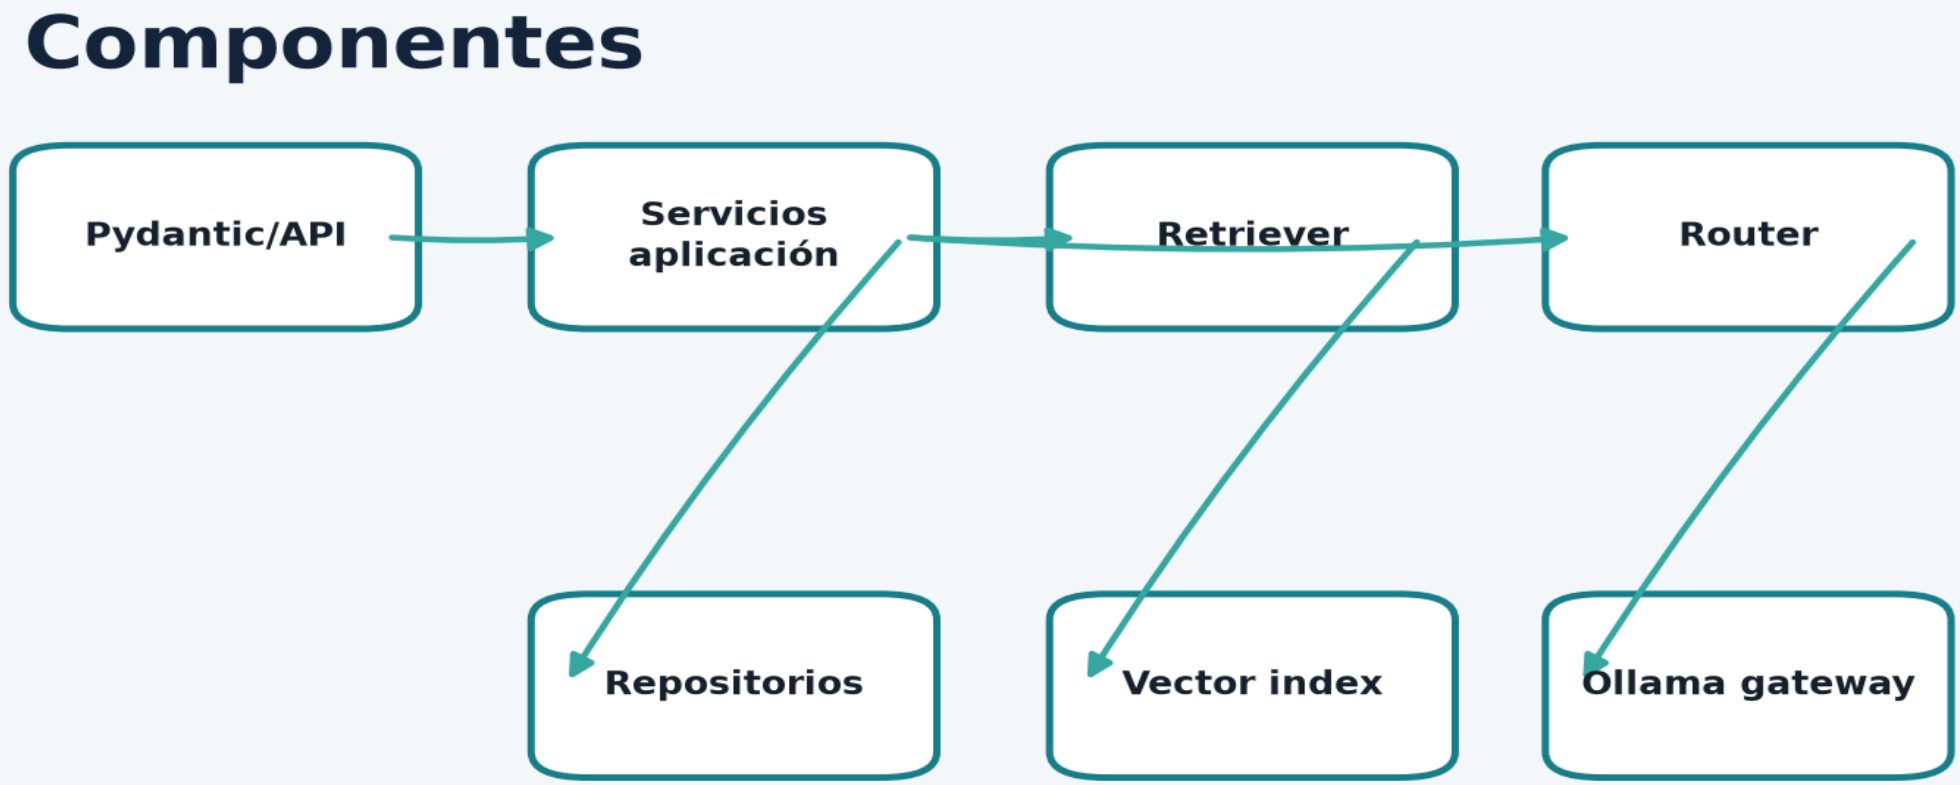
Contexto: usuarios y frontera externa



Fuente: docs/architecture/diagrams.md

Figura 1 · El registro de Ollama sólo participa al instalar; no en tiempo de ejecución.

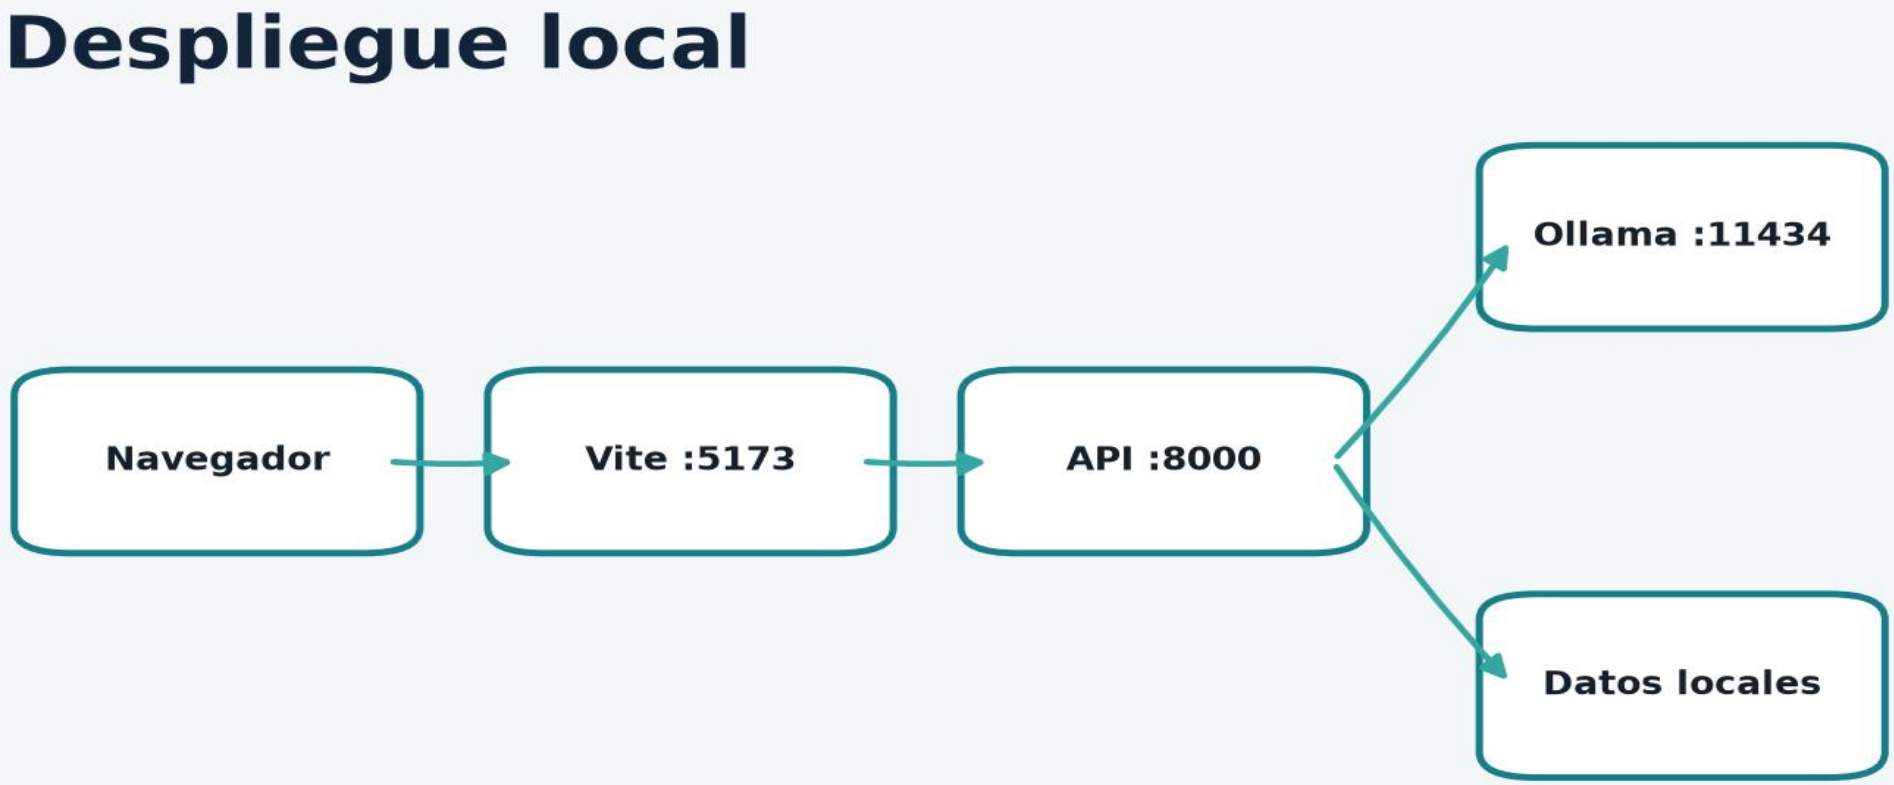
Componentes e interfaces



Fuente: docs/architecture/diagrams.md

Figura 4 · La composición conecta servicios, puertos y adaptadores.

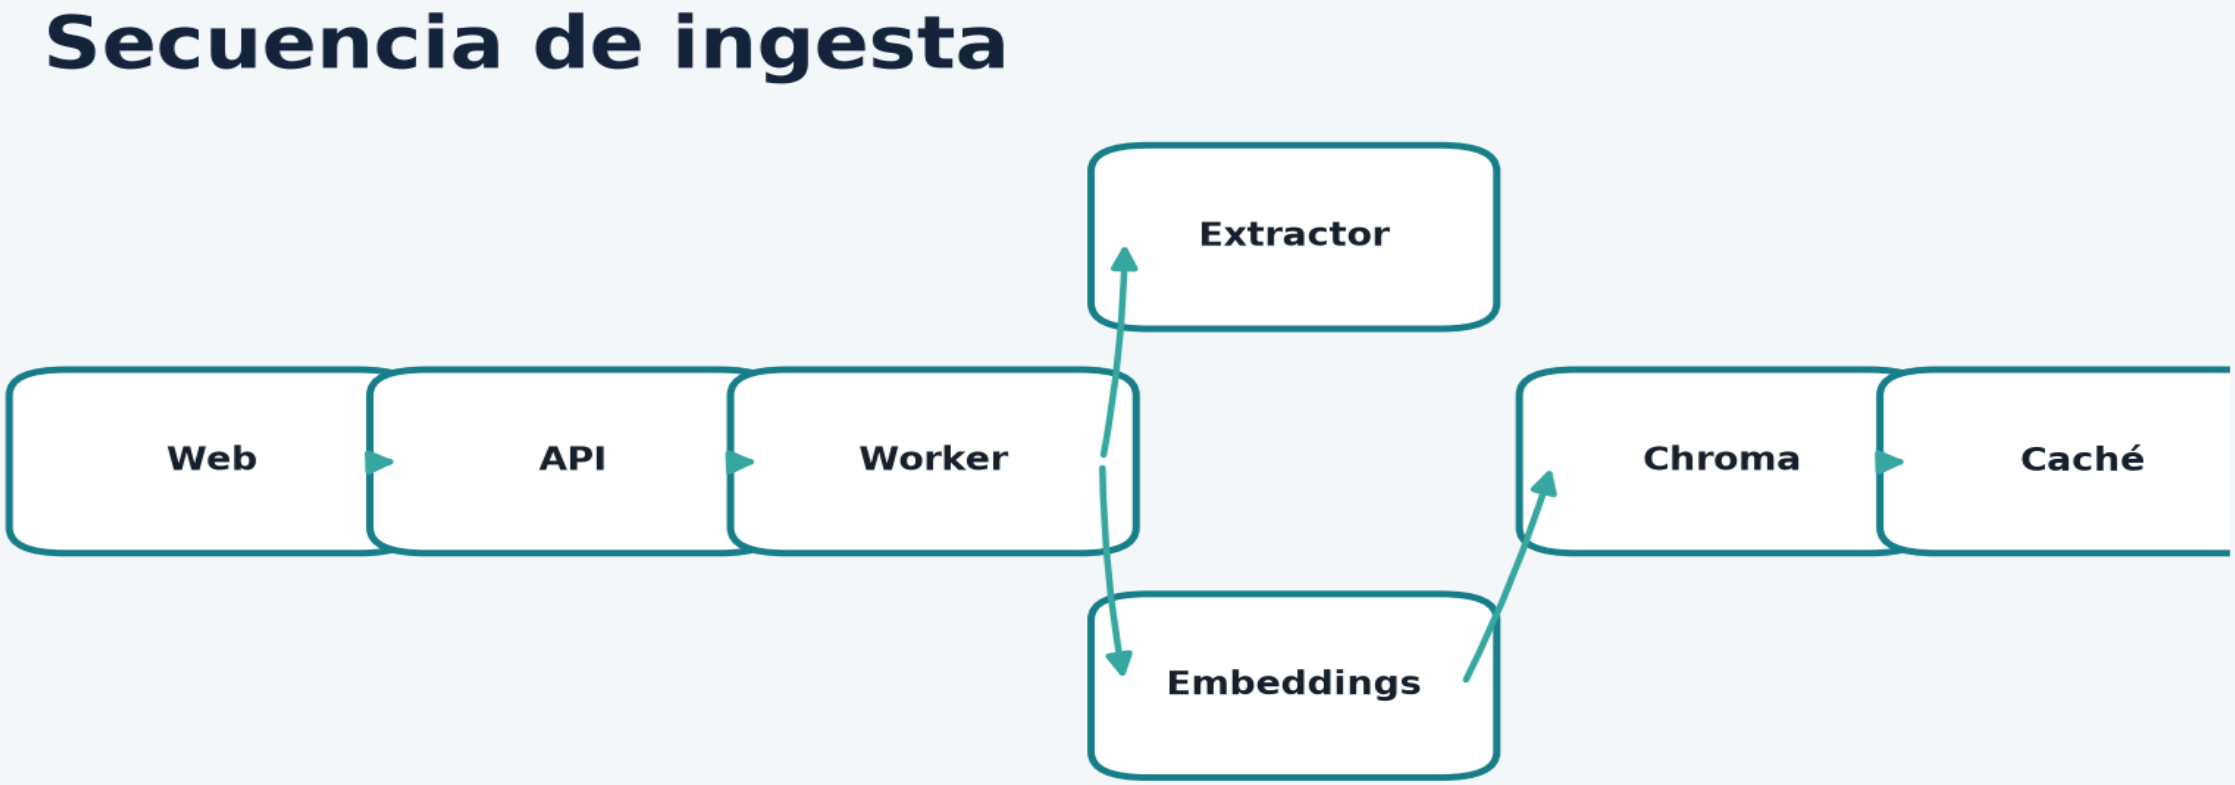
Despliegue local y recursos



Fuente: docs/architecture/diagrams.md

Figura 5 · Mac Apple Silicon 16–18 GB; procesos 5173/8000/11434 y datos locales.

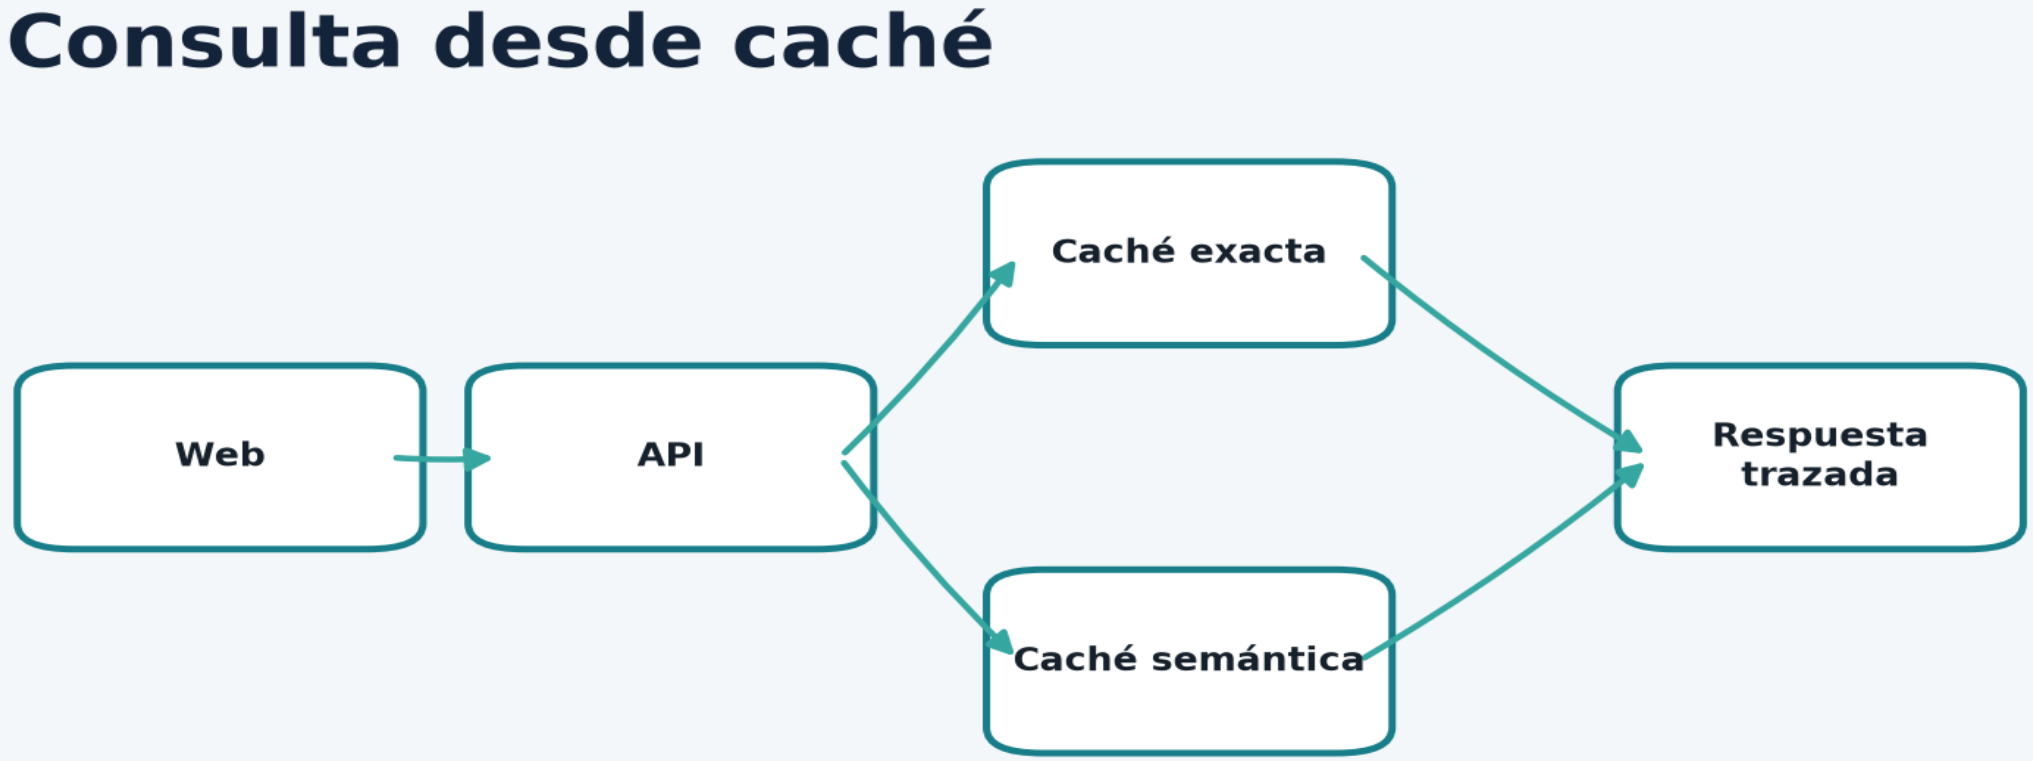
Secuencia de ingesta



Fuente: docs/architecture/diagrams.md

Figura 6 · Extraer → fragmentar → incrustar → validar → publicar → invalidar caché.

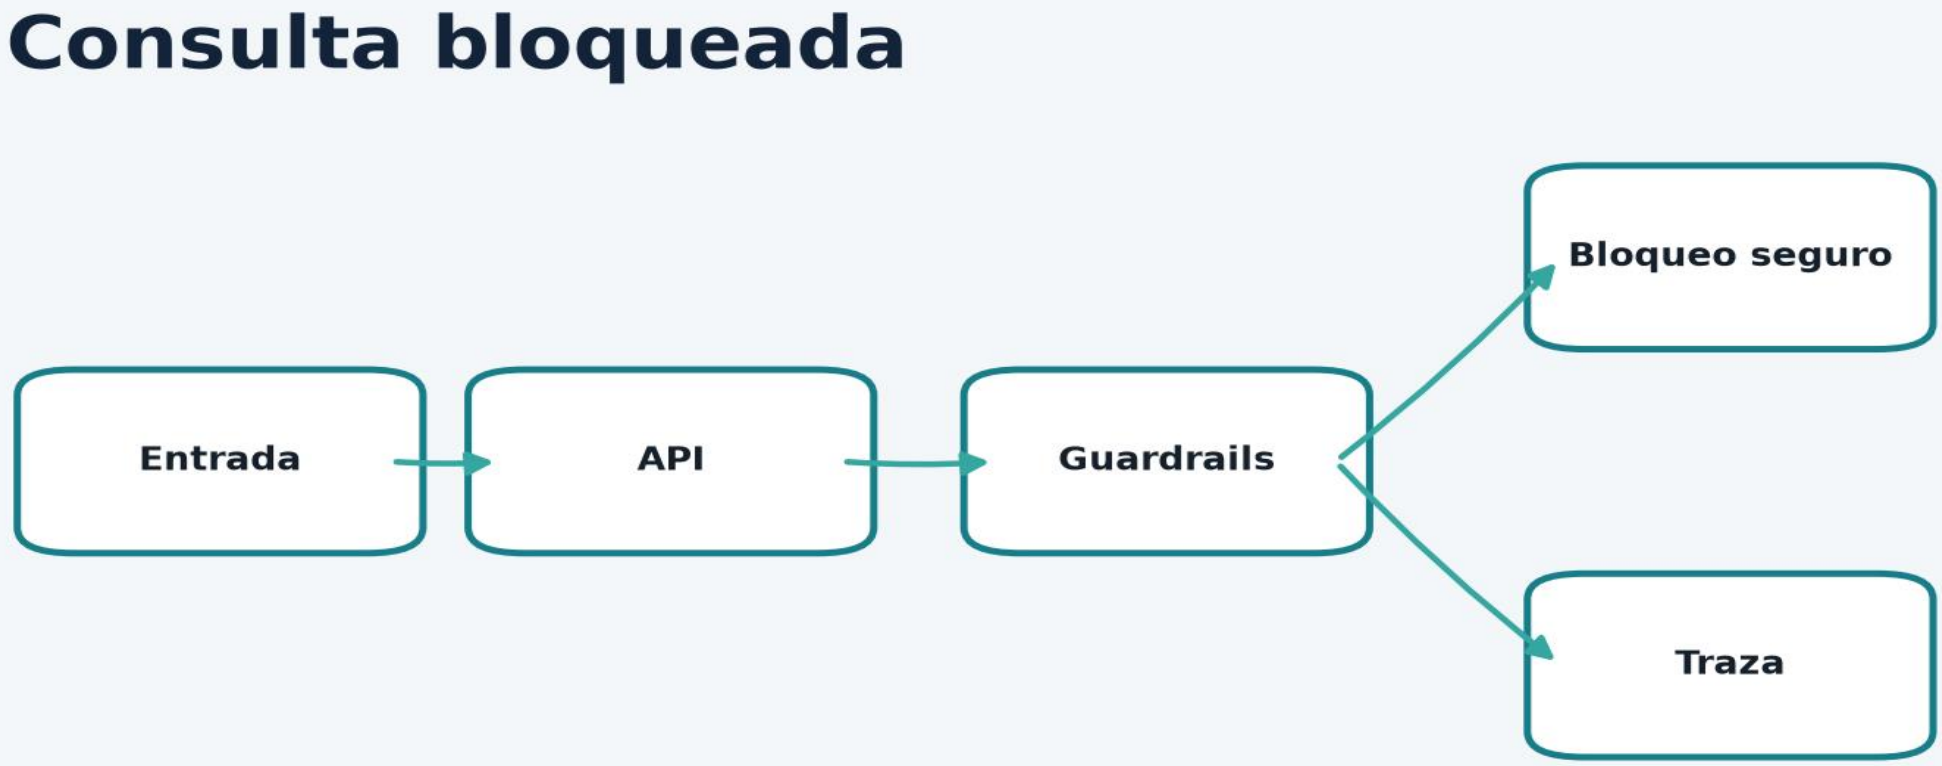
Secuencia desde caché semántica



Fuente: docs/architecture/diagrams.md

Figura 8 · Misma partición/snapshot, coseno ≥0.85 y funciones controladas idénticas.

Secuencia bloqueada por guardrail



Fuente: docs/architecture/diagrams.md

Figura 9 · Rechazo antes de recuperación o modelo; la traza conserva el motivo.

Seis ADR que sostienen la defensa

ADR	Decisión	Alternativa / costo residual
01	página + sección + metadatos	chunk fijo; umbral provisional
02	router determinista	clasificador LLM; reglas requieren mantenimiento
03	caché semántica 0.85	sólo exacta; riesgo de margen
04	guardrails en código	moderador LLM; OOD no cubierto
05	agente máx. 2	bucle abierto; puede abstenerse antes
07/08	Llama/Qwen + Nomic	elección LLM provisional; regenerar índice

API: funciones mínimas y endpoints reales

Función	Endpoint
Salud	GET /health
Carga / lista / elimina	POST/GET/DELETE /api/v1/documents…
Función principal	POST /api/v1/breed-analyses
Chat fundamentado	POST /api/v1/queries
Feedback	POST /breed-analyses/{id}/feedback
Métricas	GET /api/v1/admin/metrics
Configuración	GET /api/v1/configuration
Contrato	GET /openapi.json · /docs

Una traza explica qué pasó sin exponer texto

Identidad

trace_id · analysis_id · snapshot · versiones

Decisiones

guardrail · cache_hit · ruta · modelo · fallback

Costos

latencia total y por capa · iteraciones

Aprendizaje

útil/no útil + comentario ligado a la traza

Evidencia: TraceRecorder + repositorio SQLite + `/admin/metrics`; falta análisis longitudinal de feedback real

Preguntas previsibles de defensa

Pregunta	Respuesta respaldada
¿Por qué no dejar el ranking al LLM?	La política determinista es reproducible; el LLM sólo redacta.
¿Por qué Nomic si BGE-M3 tiene mejor MRR?	Empata puertas finales, tarda menos de la mitad y ocupa ~¼.
¿Un 1.0 significa resuelto?	No; describe un dataset acotado, no generalización.
¿Por qué dos modelos?	Router/fallback separan complejidad y resiliencia; elección provisional.
¿Qué ocurre sin evidencia?	Reformula hasta 2; después se abstiene.
¿Es realmente offline?	Arquitectura local; ensayo desconectado final aún pendiente.

Fuentes de evidencia y estado final

Norma: docs/references/Proyecto_integrador_RAG.pdf

Arquitectura: docs/architecture/diagrams.md · pruebas de fronteras

Decisiones: docs/adr/ADR-01…09

Evaluación: evaluation/runs/ · datasets/ · acceptance-gates-v1

Informe: K9-BreedMatch-Informe-Tecnico.pdf

Brechas: G1, revisión humana, especialista, permiso de corpus, offline y clon limpio